

Reporte:Singular Value Decomposition on GPU using CUDA

Oliab Herrera Coria 107863

Contents

Métodos de Primer orden.	1
Regularizaciones suaves.	1
Composite objectives	2
Escalamiento de Grandes Datos vía Aleatorización	2
Gradiente estocástico.	2
Computo Distribuido y en paralelo	2
Conclusiones	2

En los últimos años, dado el gran escalamiento en cantidad de datos y la necesidad de analizarlos, se han popularizado algoritmos, como aquellos utilizados en aprendizaje estadístico, que utilizan la optimización convexa para analizar y encontrar soluciones a problemas de terabites de información.

Actualmente, los algoritmos de optimización en grandes datos tienen tres vertientes:

- Métodos de primer orden.
- Aleatorización.
- Cómputo paralelo y distribuido.

Métodos de Primer orden.

Estos métodos utilizan información de primer orden de la función objetivo tal como los gradientes o aproximaciones para transformar el problema inicial en uno similar pero que tenga mejores “propiedades” para el cálculo de sus soluciones. Estos métodos son robustos y tienen tasas de convergencia que no dependen de la dimensión de los datos.

En el artículo el autor utiliza el *proximal gradient framework*, ya que usan descenso gradiente como base del problema, para demostrar que las regularizaciones no-suaves (Lasso) pueden ser resueltas de manera tan eficiente como las regularizaciones suaves.

Regularizaciones suaves.

El autor empieza hablando del método de descenso gradiente que es dado por la ecuación:

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k)$$

Aunque este método no es el más rápido, el autor plantea un algoritmo (El método de Nesterov) que nos da el mínimo de pasos para llegar a una solución con un grado ϵ de error.

Otra opción es convertir un problema *convexo* en un problema *estrictamente convexo* agregando un término de regularización cuadrático $\frac{\lambda}{2} \|x\|^2$ al problema

Composite objectives

Esto consiste en utilizar aproximaciones cuadráticas a la función objetivo para convertir el problema en uno estrictamente convexo

Escalamiento de Grandes Datos vía Aleatorización

Su mayor diferencia con los otros métodos de aproximación es que se tiene un control del comportamiento esperado. Las implementaciones de este tipo incluyen el cambiar cálculos exactos que son caros computacionalmente por aproximaciones, acelerar rutinas de álgebra vía aleatorización.

Gradiente estocástico.

El método de gradiente estocástico utiliza todos los datos disponibles pero usa gradientes aproximados:

El algoritmo es el siguiente: - Elige $j_k \in \{1, \dots, n\}$ de manera que sea aleatorio uniforme. - Calcula el descenso de gradiente $x^{k+1} = x^k - \alpha_k \nabla f_{j_k}(x^k)$

Computo Distribuido y en paralelo

Gracias a los avances tecnológicos el poder de cómputo y procesamiento de las máquinas han dado un boost a la capacidad de realizar cálculos que son utilizados en problemas de optimización convexa. Para poder manejar la cantidad de datos que tenemos actualmente hay que utilizar técnicas de cómputo distribuido y en paralelo.

Existen dos elementos que pueden dificultar el uso de estas tecnologías.

- Comunicación entre máquinas o procesos internos pueden disminuir la eficiencia de los algoritmos.
- Sincronización, la sincronización entre procesos puede ralentizar los algoritmos, como lo vimos en clase con los threads.

Esto para adaptar métodos que ya existían, algunos enunciados arriba, de manera que se aprovechen las ventajas tecnológicas. Pero que a la hora de ser implementados tomen en cuenta la comunicación y sincronización para poder ejecutarse de manera eficiente.

Conclusiones

El autor nos describe diferentes maneras de solucionar los problemas que vienen con el análisis de grandes datos. Desde opciones más tradicionales como el descenso de gradiente hasta el uso de cómputo distribuido, tenemos en nuestras manos herramientas muy poderosas que nos permiten enfrentar estos problemas, pero sin perder de vista que son problemas matemáticos que usan la computación como herramienta